학습 내용

3부. 데이터 분석 라이브러리 활용

11장. N차원 배열 다루기

12장. 데이터프레임과 시리즈

13장. 데이터 시각화

14장. 웹 데이터 수집

- 1절. 판다스 패키지
- 2절. 데이터프레임 만들기
- 3절. 이름 지정하기
- 4절. 부분 데이터 조회
- 5절. 데이터 삭제 및 추가
- 6절. 데이터 프레임 병합과 연결
- 7절. 정렬
- 8절. 기초 통계 분석
- 9절. 데이터 그룹화 및 집계
- 10절. 데이터 구조 변경
- 11절. 데이터프레임에 함수 적용하기
- 12절. 일괄 변경하기(결측치외)
- 13절. 시리즈

•https://pypi.python.org/pypi/pandas (package index)
•http://pandas.pydata.org/pandas-docs/stable/api.html (API reference)

1.1. 판다스 소개

1절. 판다스 패키지

- 1차원 구조를 갖는 시리즈(Series)와 2차원 구조를 갖는 데이터프레임(DataFrame)을 제공
- 데이터프레임은 테이블 형식이고 이종모음들로 구조화 된 데이터를 말하는데 엑셀의 시트 또는 스프레드시트 형식의 데이터
- 시리즈는 시계열 데이터를 표현하기 위한 데이터 구조.
  - 시리즈는 데이터프레임에서 열(Column) 하나를 의미
- 판다스의 데이터프레임과 시리즈 데이터 구조는 재무, 통계, 사회 과학 등 다양한 분야의 데이터를 처리하기 위해 사용
- 판다스는 데이터의 부분집합 조회, 열 추가 및 제거, 병합, 데이터 구조 변경 등 데이터 전처리를 위한 많은 기능을 제공
- 다음처럼 다양한 종류의 데이터를 처리하기에 적합
  - SQL 테이블 또는 Excel 스프레드시트에서와 같이 열(column) 단위로 데이터의 타입이 지정된 테이블 형식
  - 순서가 있고 정렬되지 않은 시계열 데이터.
  - 행 및 열 레이블이 포함 된 임의의 행렬 데이터(동종 유형 또는 이종 유형)

DataFrame

- 2차원(행, 열) 구조(엑셀 시트 구조)
  - 행(Row)
    - 1개 행은 각각 다른 데이터를 갖는 튜플
    - 행의 이름과 인덱스(위치)를 가짐
    - 행의 이름은 인덱스와 같을 경우가 많음
  - 열(Column)
    - 열 내의 모든 데이터는 같은 타입
    - 열의 이름과 인덱스(위치)를 가짐

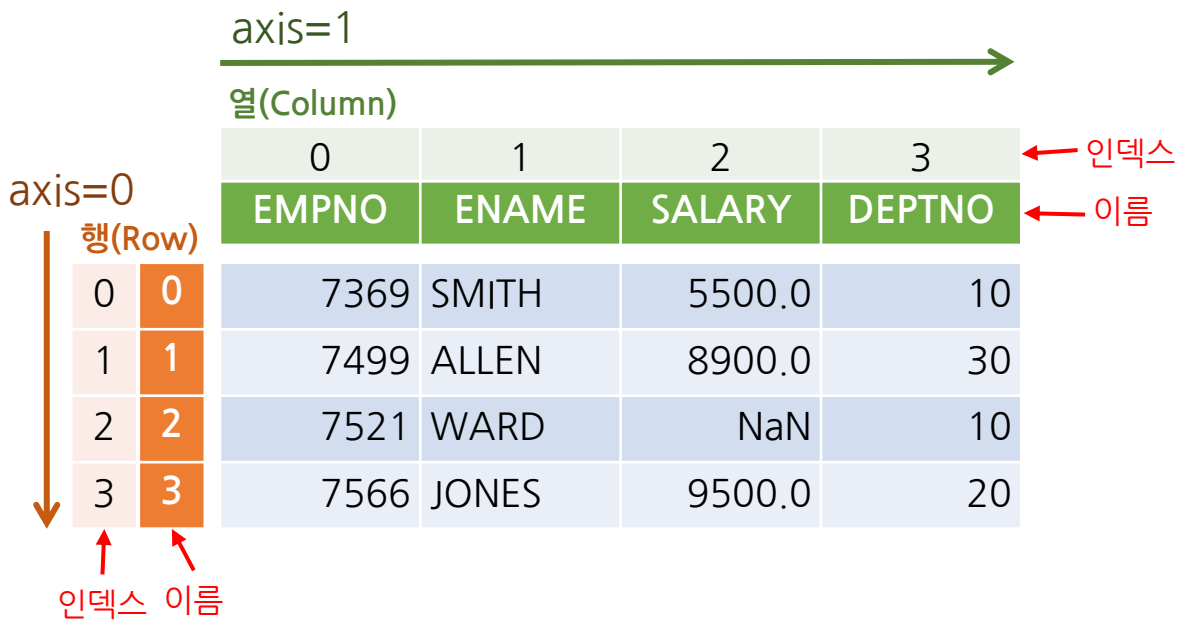

	0	1	2	3
	EMPNO	ENAME	SALARY	DEPTNO
0	7369	SMITH	5500.0	10
1	7499	ALLEN	8900.0	30
2	7521	WARD	NaN	10
3	7566	JONES	9500.0	20

1.2. 판다스 장점

1절. 판다스 패키지

- 데이터프레임 생성 : 다른 파이썬 및 넘파이 데이터 구조의 비정형 색인 데이터를 데이터프레임 객체로 쉽게 변환 할 수 있음
- 파일 입출력 : CSV 파일 또는 구분자에 의한 플랫 파일, Excel 파일, 데이터베이스 및 초고 속 HDF5 형식의 데이터 저장/로드를 위한 입출력 도구를 제공
- 레이블링 : 축의 계층적 레이블링(다중 레이블을 가질 수 있음)을 제공
- 부분 데이터 셋 추출 : 지능형 레이블 기반 슬라이싱, 고급 인덱싱 및 대용량 데이터 세트의 하위 집합을 사용할 수 있음
- 데이터 추가 : 데이터프레임에 열을 삽입하고 삭제할 수 있음
- 데이터 분할 및 병합 : 데이터를 집계 및 변환하기 위해 데이터 세트에 분할 및 병합 작업을 수행 할 수 있는 강력하고 유연한 그룹 별 기능을 제공
- 데이터 정렬 : 개체를 레이블 세트에 명시적으로 정렬하거나 사용자가 레이블을 무시하고 시 리즈, 데이터프레임 등으로 자동으로 데이터를 정렬에 사용할 수 있음
- 결측치(Missing Value) 처리 : 부동 소수점 데이터뿐만 아니라 누락 된 데이터(NaN으로 표시됨)를 손쉽게 처리할 수 있음
- 피벗과 언피벗 : 데이터 세트의 피벗 및 언피벗 기능을 제공
- 시계열 관련 기능 : 날짜 범위 생성 및 빈도 변환, 통계, 선형 회귀 등을 사용할 수 있음

1.2. 판다스 기본 API - 파일 i/o함수

함수	설명
read_pickle(path[, compression])	피클에 의해 저장된 데이터를 불러옵니다. 데이터프레임을 피클링하려면 DataFrame.to_pickle() 함수를 사용합니다.
read_table(filepath_or_buffer[, sep, ...])	구분자를 지정하여 파일 데이터를 데이터프레임 객체로 불러들입니다.
read_csv(filepath_or_buffer[, sep, ...])	CSV(comma-separated) 파일을 데이터프레임 객체로 불러들입니다. 데이터프레임을 CSV 파일로 저 장하려면 DataFrame.to_csv() 함수를 사용합니다.
read_clipboard([sep])	클립보드로부터 텍스트를 읽어 read_table에 전달합니다. DataFrame.to_clipboard()를 이용하면 객체 를 클립보드에 복사할 수 있습니다.
read_excel(io[, sheet_name, header, ...])	Excel 데이터를 데이터프레임 객체로 불러들입니다. DataFrame.to_excel()을 데이터프레임을 엑셀 시트에 저장합니다.
read_json([path_or_buf, orient, typ, dtype, ...]	JSON 문자열을 판다스 객체로 불러들입니다. 데이터프레임을 JSON 형식으로 저장하려면 DataFrame.to_json() 함수를 이용합니다.
read_html(io[, match, flavor, header, ...])	HTML을 데이터프레임 객체 리스트로 불러들입니다. 데이터프레임을 HTML 테이블로 만들려면 DataFrame.to_html() 함수를 사용합니다.
read_hdf(path_or_buf[, key, mode])	HDF Store에서 읽습니다. 데이터프레임을 HDF5 형식으로 저장하려면 DataFrame.to_hdf()를 이용합니다.

1.2. 판다스 기본 A P I - 데이터 조작 함수

함수	설명
melt(frame[, id_vars, value_vars, var_name, ...])	언피봇(Unpivot) 합니다.
pivot(index, columns, values)	데이터프레임의 3 컬럼 정보를 이용하여 피벗(Pivot) 테이블을 생성합니다.
pivot_table(data[, values, index, columns, ...])	데이터프레임으로 스프레드시트 유형의 피벗 테이블을 생성합니다.
crosstab(index, columns[, values, rownames, ...])	두 개 또는 그 이상의 팩터(Factor)를 이용하여 크로스탭(cross-tabulation) 테이블을 계산합니다.
cut(x, bins[, right, labels, retbins, ...])	x를 포함하는 각 값의 인덱스 절반을 반환합니다.
qcut(x, q[, labels, retbins, precision, ...])	Quantile 기반 이산화 함수를 반환합니다.
merge(left, right[, how, on, left_on, ...])	열 또는 인덱스별로 조인 작업을 수행하여 데이터프레임 객체를 병합합니다.
merge_ordered(left, right[, on, left_on, ...])	시계열 데이터와 같은 정렬 된 데이터를 위해 설계된 선택적인 채우기(filling)/보간(interpolation)을 사용하여 병합을 수행합니다.
merge_asof(left, right[, on, left_on, ...])	asof 병합을 실행합니다. 이것은 등호가 아닌 가장 가까운 키와 일치한다는 점을 제외하고는 왼쪽 조인(left join)과 유사합니다.
concat(objs[, axis, join, join_axes, ...])	다른 축을 따라 선택적 집합 논리로 특정 축을 따라 객체를 연결합니다.
get_dummies(data[, prefix, prefix_sep, ...])	범주 형 변수를 더미(dummy) 변수/지시(indicator) 변수로 변환합니다.
factorize(values[, sort, order, ...])	입력 값을 열거 형 또는 범주 형 변수로 인코딩합니다.
unique(values)	해시 테이블 기반 고유 값을 생성합니다.
wide_to_long(df, stubnames, i, j[, sep, suffix])	와이드 패널(wide panel)을 긴 형식.(long format)으로 변환합니다.

1.2. 판다스 디스플레이 옵션

판다스에서 데이터를 화면에 출력할 때 모든 열과 행을 화면에 표시해 주지는 않음

열의 수 또는 행의 수가 많을 경우 일부 열과 행은 ... 으로 표시

더 많은 열 정보를 출력하고 싶다면… pd.options.display.max_columns = 999

자주 사용되는 판다스 디스플레이 옵션

옵션	설명
display.max_rows	표시할 최대 행의 수를 설정합니다.
display.max_columns	표시할 최대 열의 수를 설정합니다.
display.expand_frame_repr	데이터프레임을 여러 줄에 걸쳐 인쇄할지 여부(True/False)를 결정합니다. max_columns는 적용되지만 width가 display.width를 초과하면 여러 페이지에 표 시됩니다.
display.max_colwidth	표시할 열의 최대 너비를 설정합니다.
display.precision	10진수의 정밀도(precision)를 설정합니다.

2.1. 딕셔너리를 이용해서 데이터프레임 만들기

2절. 데이터프레임 만들기

- 딕셔너리를 이용해 데이터프레임을 만들면 키가 열 이름이 됨

```
DataFrame(data=None, index=None, columns=None, dtype=None,
          copy=False)
```

```
1  import pandas as pd
```

```
1  d = {'col1': [1, 2], 'col2': [3, 4]}
2  df = pd.DataFrame(data=d)
3  df
```

	col1	col2
0	1	3
1	2	4

```
1  d = [{'col1': 1, 'col2': 3}, {'col1': 2, 'col2': 4}]
2  df = pd.DataFrame(data=d)
3  df
```

	col1	col2
0	1	3
1	2	4

```
1  d = [{'col1': 1, 'col2': 3}, {'col1': 2, 'col2': 4},
2       {'col1': 2}]
3  df = pd.DataFrame(data=d)
4  df
```

	col1	col2
0	1	3.0
1	2	4.0
2	2	NaN

2.2. 리스트를 이용해 데이터프레임 만들기

2절. 데이터프레임 만들기

- 리스트를 이용하려면 딕셔너리의 값으로 지정하거나

```
1  a = [1,2,3,4,5]
2  b = [6,7,8,9,10]
3  df = pd.DataFrame({"col1": a, "col2": b})
4  df
```

	col1	col2
0	1	6
1	2	7
2	3	8
3	4	9
4	5	10

- np.c_로 열 단위 결합 후 열 이름 지정

```
1  import numpy as np
2  a = [1,2,3,4,5]
3  b = [6,7,8,9,10]
4  df = pd.DataFrame(np.c_[a, b], columns=["col1", "col2"])
5  df
```

	col1	col2
0	1	6
1	2	7
2	3	8
3	4	9
4	5	10

1) CSV 파일 불러오기

- read_csv()

```
pandas.read_csv(filepath_or_buffer, sep=', ', delimiter=None,
                header='infer', ...)
```

```
1  import pandas as pd
2  member_df = pd.read_csv("member_data.csv", sep=",")
```

```
1  member_df
```

	Name	Age	Email	Address
0	홍길동	20	kildong@hong.com	서울시 강동구
1	홍길서	25	kilseo@hong.com	서울시 강서구
2	홍길남	26	south@hong.com	서울시 강남구
3	홍길북	27	book@hong.com	서울시 강북구

샘플 데이터(member_data.csv)

```
Name,Age,Email,Address
홍길동,20,kildong@hong.com,서울시 강동구
홍길서,25,kilseo@hong.com,서울시 강서구
홍길남,26,south@hong.com,서울시 강남구
홍길북,27,book@hong.com,서울시 강북구
```

2) 행 제외하기

- skiprows=[제외할 행들]

```
1  member_df = pd.read_csv("member_data.csv", skiprows=[0,2])
```

```
1  member_df
```

	홍길동	20	kildong@hong.com	서울시 강동구
0	홍길남	26	south@hong.com	서울시 강남구
1	홍길북	27	book@hong.com	서울시 강북구

```
1  member_df = pd.read_csv("member_data.csv", skiprows=[1,3])
2  member_df
```

	Name	Age	Email	Address
0	홍길서	25	kilseo@hong.com	서울시 강서구
1	홍길북	27	book@hong.com	서울시 강북구

3) 주석행 지정하기

- comment='#'

```
1  member_df = pd.read_csv("member_data.csv")
2  member_df
```

	Name	Age	Email	Address
0	홍길동	20	kildong@hong.com	서울시 강동구
1	홍길서	25	kilseo@hong.com	
2	홍길남	26	south@hong.com	
3	홍길북	27	book@hong.com	
4	#홍흉동	30	bad@hong.com	

샘플 데이터(member_data.csv)

```
Name,Age,Email,Address
홍길동,20,kildong@hong.com,서울시 강동구
홍길서,25,kilseo@hong.com,서울시 강서구
홍길남,26,south@hong.com,서울시 강남구
홍길북,27,book@hong.com,서울시 강북구
#홍흉동,30,bad@hong.com,주소 없음
```

```
1  member_df = pd.read_csv("member_data.csv", comment='#')
2  member_df
```

	Name	Age	Email	Address
0	홍길동	20	kildong@hong.com	서울시 강동구
1	홍길서	25	kilseo@hong.com	서울시 강서구
2	홍길남	26	south@hong.com	서울시 강남구
3	홍길북	27	book@hong.com	서울시 강북구

에드거 엔더슨(Edgar Anderson)의 iris 데이터셋

붓꽃(iris)의 3가지 종(setosa(세토사), versicolor(버시컬러), virginica(버지니카))별로 각각 50개 데이터의 꽃받침의 길이와 너비, 꽃잎의 길이와 너비를 센티미터 단위로 측정하여 정리한 데이터 셋

Seq	열 이름	타입	상세
1	Sepal.Length 또는 sepal_length	float	. 꽃받침 길이
2	Sepal.Width 또는 sepal_width	float	. 꽃받침 너비
3	Petal.Length 또는 petal_length	float	. 꽃잎 길이
4	Petal.Width 또는 petal_length	float	. 꽃잎 너비
5	Species 또는 species	str	. 종(setosa, versicolor, virginica)

2.4. sklearn.datasets 모듈 데이터를 데이터프레임으로 변환하기

2절. 데이터프레임 만들기

- Scikit-learn 패키지에는 학습을 위한 많은 데이터셋이 제공
- Scikit-learn에서 제공하는 데이터셋은 딕셔너리 형식
  - data, target, target_names, DESCR, feature_names등의 key를 가짐

```
1  import numpy as np
2  import pandas as pd
3  from sklearn import datasets
```

```
1  iris = datasets.load_iris()
2  iris
```

```
{'data': array([[5.1, 3.5, 1.4, 0.2],
        [4.9, 3. , 1.4, 0.2],
        [4.7, 3.2, 1.3, 0.2],
        [4.6, 3.1, 1.5, 0.2],
        [5. , 3.6, 1.4, 0.2],
```

```
1  x = pd.DataFrame(iris.data, columns=iris.feature_names)
2  y = pd.DataFrame(iris['target_names'][iris['target']],
3                   columns=["species"])
```

```
1  iris_df = pd.concat([x,y], axis=1)
```

```
1  iris_df.head()
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

종속변수 지정하기

2절. 데이터프레임 만들기

```
y = pd.DataFrame(iris.target, columns=["species"])
```

```
iris_df = pd.concat([x,y], axis=1)
```

```
iris_df.head()
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	species
0	5.1	3.5	1.4	0.2	0
1	4.9	3.0	1.4	0.2	0
2	4.7	3.2	1.3	0.2	0
3	4.6	3.1	1.5	0.2	0
4	5.0	3.6	1.4	0.2	0

2.4. statsmodels 패키지의 iris 데이터 셋

- **statsmodels 패키지의 get_rdataset() 함수를 이용해서 iris 데이터를 불러올 수 있음**
- **get_rdataset()의 반환 값은 statsmodels.data.utils.Dataset 객체**
  - data : 데이터를 포함하는 판다스의 데이터프레임
  - title : 데이터셋의 제목
  - package : 데이터가 들어있는 R의 패키지
  - from_cache : 캐시된 데이터가 검색되지 않았는지 여부
  - _____doc___: R 설명서

```
1  import statsmodels.api as sm
2  iris_data = sm.datasets.get_rdataset("iris", package="datasets",
3                                        cache=True)
```

```
1  type(iris_data)
```

```
statsmodels.datasets.utils.Dataset
```

2.4. seaborn 패키지의 iris 데이터 셋

- **seaborn 패키지의 load_dataset() 함수를 이용하면 iris 데이터프레임을 쉽게 가져옴**

```
1 import seaborn as sns
```

```
1 iris = sns.load_dataset("iris")
```

```
1 iris.head()
```

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

데이터프레임의 열 이름 변경하기

2절. 데이터프레임 만들기

- columns 속성 이용 열 이름 지정

```
1 iris_df.columns = ["sepal_length", "sepal_width", "petal_length",
2                    "petal_width", "species"]
```

```
1 iris_df.head()
```

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	0
1	4.9	3.0	1.4	0.2	0
2	4.7	3.2	1.3	0.2	0
3	4.6	3.1	1.5	0.2	0
4	5.0	3.6	1.4	0.2	0

3.1. 열 이름 지정하기

3절. 이름 지정하기

- columns 속성 이용 열 이름 지정

```
1  member_df.columns = ["이름", "나이", "이메일", "주소"]
2  member_df
```

	이름	나이	이메일	주소
0	홍길동	20	kildong@hong.com	서울시 강동구
1	홍길서	25	kilseo@hong.com	서울시 강서구
2	홍길남	26	south@hong.com	서울시 강남구
3	홍길북	27	book@hong.com	서울시 강북구

```
1  member_df.columns
```

```
Index(['이름', '나이', '이메일', '주소'], dtype='object')
```

3.2. 행 이름 지정하기

3절. 이름 지정하기

- index 속성 이용 행 이름 지정

```
1  member_df.index = ["동", "서", "남", "북"]
2  member_df
```

	이름	나이	이메일	주소
동	홍길동	20.0	kildong@hong.com	서울시 강동구
서	홍길서	25.0	kilseo@hong.com	서울시 강서구
남	홍길남	26.0	south@hong.com	서울시 강남구
북	홍길북	27.0	book@hong.com	서울시 강북구

3.3. 레벨 이름 지정하기

3절. 이름 지정하기

- 열 이름과 행 이름을 2차원으로 지정하고 names 속성을 이용해서 레벨 이름 지정

```
member_df = pd.read_csv("member_data.csv", comment='#')
```

```
member_df.columns = [["기본정보", "기본정보", "추가정보", "추가정보"],
                     ["이름", "나이", "이메일", "주소"]]
member_df.columns.names = ["정보구분", "상세정보"]
```

```
member_df.index = [["좌우","좌우","상하","상하"],
                   ["동", "서", "남", "북"]]
member_df.index.names = ["위치구분", "상세위치"]
```

```
member_df
```

	정보구분	기본정보		추가정보	
	상세정보	이름	나이	이메일	주소
위치구분	상세위치				
좌우	동	홍길동	20	kildong@hong.com	서울시 강동구
	서	홍길서	25	kilseo@hong.com	서울시 강서구
상하	남	홍길남	26	south@hong.com	서울시 강남구
	북	홍길북	27	book@hong.com	서울시 강북구

4.1. 단일 열 조회

4절. 부분 데이터 조회

- 데이터프레임.*열이름*
- 데이터프레임*["열이름"]*
  - 열 이름에 . 또는 공백 등이 포함되어 있을 경우 사용

```
1  member_df.Name
```

```
0    홍길동
1    홍길서
2    홍길남
3    홍길북
Name: Name, dtype: object
```

```
1  member_df["Name"]
```

```
0    홍길동
1    홍길서
2    홍길남
3    홍길북
Name: Name, dtype: object
```

4.2. loc를 이용한 이름으로 조회

4절. 부분 데이터 조회

- loc[행이름, 열이름]
- 열이름 생략 가능

```
1  member_df.loc[0:2]
```

열 이름을 생략하면 행 이름으로 찾음

	Name	Age	Email	Address
0	홍길동	20	kildong@hong.com	서울시 강동구
1	홍길서	25	kilseo@hong.com	서울시 강서구
2	홍길남	26	south@hong.com	서울시 강남구

```
1  member_df.loc["Name":"Email"] # nothing
```

열 이름을 생략하면 행 이름으로 찾음

	Name	Age	Email	Address

슬라이싱으로 찾기

```
1  member_df.loc[0:2, "Name":"Email"]
```

	Name	Age	Email
0	홍길동	20	kildong@hong.com
1	홍길서	25	kilseo@hong.com
2	홍길남	26	south@hong.com

```
1  member_df.loc[[0,2], ["Name","Email"]]
```

리스트로 찾기

	Name	Email
0	홍길동	kildong@hong.com
2	홍길남	south@hong.com

4.3. iloc를 이용한 인덱스로 조회

4절. 부분 데이터 조회

- iloc[행인덱스, 열인덱스]

```
1  member_df.iloc[1:3, 1:3]
```

	Age	Email
1	25	kilseo@hong.com
2	26	south@hong.com

```
1  member_df.iloc[0:3, 0:3]
```

	Name	Age	Email
0	홍길동	20	kildong@hong.com
1	홍길서	25	kilseo@hong.com
2	홍길남	26	south@hong.com

```
1  member_df.iloc[::-1]
```

	Name	Age	Email	Address
3	홍길북	27	book@hong.com	서울시 강북구
2	홍길남	26	south@hong.com	서울시 강남구
1	홍길서	25	kilseo@hong.com	서울시 강서구
0	홍길동	20	kildong@hong.com	서울시 강동구

```
1  member_df.iloc[0::2,[1,3]]
```

	Age	Address
0	20	서울시 강동구
2	26	서울시 강남구

4.4 조건으로 조회하기

4절. 부분 데이터 조회

- 예제에 사용할 데이터
- statsmodels 패키지의 get_rdataset() 함수 이용

```
1  import numpy as np
2  import pandas as pd
```

```
1  import statsmodels.api as sm
2  iris = sm.datasets.get_rdataset("iris", package="datasets")
```

```
1  iris
```

```
<class 'statsmodels.datasets.utils.Dataset'>
```

4.4 조건으로 조회하기

4절. 부분 데이터 조회

- get_rdataset() 함수로 불러온 데이터의 data 속성은 데이터를 담고 있는 데이터프레임

```
1  iris_df = iris.data
2  iris_df.head()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

4.4 조건으로 조회하기

4절. 부분 데이터 조회

- loc[행조건] : 행 조건에 맞는 모든 열을 반환

```
1  iris_df.loc[iris_df['Species']=='versicolor'].head()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
50	7.0	3.2	4.7	1.4	versicolor
51	6.4	3.2	4.5	1.5	versicolor
52	6.9	3.1	4.9	1.5	versicolor
53	5.5	2.3	4.0	1.3	versicolor
54	6.5	2.8	4.6	1.5	versicolor

4.4 조건으로 조회하기

4절. 부분 데이터 조회

- loc[행조건, 열리스트] : 행 조건에 맞는 지정한 열을 반환

```
1  iris_df.loc[iris_df['Species']=='versicolor',
2              ['Sepal.Length', 'Species']].head()
```

	Sepal.Length	Species
50	7.0	versicolor
51	6.4	versicolor
52	6.9	versicolor
53	5.5	versicolor
54	6.5	versicolor

4.4 조건으로 조회하기

4절. 부분 데이터 조회

- loc[중복조건]

```
1  iris_df.loc[(iris_df['Species']=='versicolor') &
2              (iris_df['Sepal.Length'].astype(float) > 6.5)].head()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
50	7.0	3.2	4.7	1.4	versicolor
52	6.9	3.1	4.9	1.5	versicolor
58	6.6	2.9	4.6	1.3	versicolor
65	6.7	3.1	4.4	1.4	versicolor
75	6.6	3.0	4.4	1.4	versicolor

5.1. 데이터프레임의 항목 삭제

5절. 데이터 추가 및 삭제

```
DataFrame.drop(labels=None, axis=0, inplace=False)
```

구문에서...

- *labels* : 삭제할 index 또는 컬럼의 이름을 지정합니다.
- *axis* : int 타입 또는 축의 이름입니다. (0 또는 'index') 와 (1 또는 'columns') 중 하나를 갖습니다. 1이면 열을 삭제합니다.
- *inplace* : bool 타입이며, False(기본값)이면 삭제된 결과 데이터프레임을 리턴하며, True 이면 현재 데이터프레임에서 데이터를 삭제하고 None을 반환합니다.

예제에 사용할 데이터

```
1  member_df = pd.read_csv("member_data.csv", comment='#')
2  member_df.columns = ["이름", "나이", "이메일", "주소"]
3  member_df.index = ["동", "서", "남", "북"]
4  member_df
```

1) 단일 행 삭제하기

- axis=0

```
1  member_df = member_df.drop('북') #axis=0(기본값)이면 행에서 찾아 삭제
2  member_df
```

	이름	나이	이메일	주소
동	홍길동	20	kildong@hong.com	서울시 강동구
서	홍길서	25	kilseo@hong.com	서울시 강서구
남	홍길남	26	south@hong.com	서울시 강남구

2) 단일 열 삭제하기

- axis=1

```
1  member_df = member_df.drop('주소', axis=1) #axis=1이면 열에서 찾아 삭제
2  member_df
```

	이름	나이	이메일
동	홍길동	20	kildong@hong.com
서	홍길서	25	kilseo@hong.com
남	홍길남	26	south@hong.com

3) 복수일 열 삭제하기

- labels = [삭제할_열_리스트,]

```
1  member_df.drop(labels=["Email", "Address"], axis=1)
```

	Name	Age
0	홍길동	20
1	홍길서	25
2	홍길남	26
3	홍길북	27

axis=1과 axis='columns'와 동일

```
1  member_df.drop(labels=["Email", "Address"], axis="columns")
```

	Name	Age
0	홍길동	20
1	홍길서	25
2	홍길남	26
3	홍길북	27

4) 열 삭제와 재 할당

- inplace=True

```
1  member_df.drop("Address", axis=1, inplace=True)
2  member_df
```

	Name	Age	Email
0	홍길동	20	kildong@hong.com
1	홍길서	25	kilseo@hong.com
2	홍길남	26	south@hong.com
3	홍길북	27	book@hong.com

1) 열 추가

5절. 데이터 추가 및 삭제 > 5.2. 데이터프레임의 항목 추가

- 데이터프레임["새로운_열_이름"] = 값

예제에 사용할 데이터

```
1  member_df = pd.read_csv("member_data.csv", comment='#')
2  member_df["BirthYear"] = 2000
3  member_df
```

	Name	Age	Email	Address	BirthYear
0	홍길동	20	kildong@hong.com	서울시 강동구	2000
1	홍길서	25	kilseo@hong.com		
2	홍길남	26	south@hong.com		
3	홍길북	27	book@hong.com		

```
1  member_df = pd.read_csv("member_data.csv", comment='#')
2  member_df["BirthYear"] = [2001, 2002, 2003, None]
3  member_df
```

	Name	Age	Email	Address	BirthYear
0	홍길동	20	kildong@hong.com	서울시 강동구	2001.0
1	홍길서	25	kilseo@hong.com	서울시 강서구	2002.0
2	홍길남	26	south@hong.com	서울시 강남구	2003.0
3	홍길북	27	book@hong.com	서울시 강북구	NaN

2) 시리즈를 이용한 열 추가

- 인덱스를 포함하는 시리즈 객체를 이용해 추가

```
1  member_df = pd.read_csv("member_data.csv", comment='#')
2  member_df["BirthYear"] = pd.Series([2001, 2002, 2004], index=[0,1,3])
3  member_df
```

	Name	Age	Email	Address	BirthYear
0	홍길동	20	kildong@hong.com	서울시 강동구	2001.0
1	홍길서	25	kilseo@hong.com	서울시 강서구	2002.0
2	홍길남	26	south@hong.com	서울시 강남구	NaN
3	홍길북	27	book@hong.com	서울시 강북구	2004.0

3) 딕셔너리로 행 추가

- 데이터프레임 추가가 아닐때 ignore_index=True 파라미터 지정

```
1 new_member = {"Name"  : "이순신",
2               "Age"   : 30,
3               "Email" : "hong@abc.com",
4               "Address":"서울시 마포구"}
```

```
1 new_df = member_df.append(new_member, ignore_index=True)
2 new_df
```

	Name	Age	Email	Address
0	홍길동	20	kildong@hong.com	서울시 강동구
1	홍길서	25	kilseo@hong.com	서울시 강서구
2	홍길남	26	south@hong.com	서울시 강남구
3	홍길북	27	book@hong.com	서울시 강북구
4	이순신	30	hong@abc.com	서울시 마포구

4) 시리즈를 이용한 리스트 데이터의 행 추가

- 리스트는 시리즈 객체로 만들어 행 단위로 추가

```
1 new_list = ['파이썬',23,'python@hong.com','서울시 마포구']
2 new_series = pd.Series(new_list, index=member_df.columns)
3 new_df = member_df.append(new_series, ignore_index=True)
4 new_df
```

	Name	Age	Email	Address
0	홍길동	20	kildong@hong.com	서울시 강동구
1	홍길서	25	kilseo@hong.com	서울시 강서구
2	홍길남	26	south@hong.com	서울시 강남구
3	홍길북	27	book@hong.com	서울시 강북구
4	파이썬	23	python@hong.com	서울시 마포구

6절. merge()를 이용한 데이터프레임 병합

merge() 함수는 두 개 데이터프레임의 공통 열 또는 공통 인덱스를 기준으로 두 개의 데이터프레임을 하나로 합침

```
DataFrame.merge(right, how='inner', on=None,
    left_on=None, right_on=None, left_index=False,
    right_index=False, sort=False, suffixes=('_x', '_y'),
    copy=True, indicator=False, validate=None)
```

6절. how 속성

6절. 병합

```
df1 = pd.DataFrame({'key': ['a', 'b', 'c', 'f'], 'c1': [1, 2, 3, 5]})
df2 = pd.DataFrame({'key': ['a', 'b', 'd', 'f'], 'c2': [5, 6, 7, 8]})
```

```
df1.merge(df2)
```

	key	c1	c2
0	a	1	5
1	b	2	6
2	f	5	8

```
df1.merge(df2, how="left")
```

	key	c1	c2
0	a	1	5.0
1	b	2	6.0
2	c	3	NaN
3	f	5	8.0

```
df1.merge(df2, how="right")
```

	key	c1	c2
0	a	1.0	5
1	b	2.0	6
2	f	5.0	8
3	d	NaN	7

```
df1.merge(df2, how="outer")
```

	key	c1	c2
0	a	1.0	5.0
1	b	2.0	6.0
2	c	3.0	NaN
3	f	5.0	8.0
4	d	NaN	7.0

how 매개변수의 기본값은 'inner'이므로 내부 조인을 함

6절. Left_on, right_on 속성

6절. 병합

키가 되는 기준열의 이름이 두 데이터프레임에서 다르다면 left_on과 right_on 인수를 사용하여 기준이 되는 열을 명시해야 함

```
df3 = pd.DataFrame({'key3': ['a', 'b', 'c', 'f'], 'c1': [1, 2, 3, 5]})
df4 = pd.DataFrame({'key4': ['a', 'b', 'd', 'f'], 'c2': [5, 6, 7, 8]})
```

```
df3.merge(df4, left_on="key3", right_on="key4")
```

	key3	c1	key4	c2
0	a	1	a	5
1	b	2	b	6
2	f	5	f	8

6절. concat()을 이용한 데이터 프레임 연결

concat() 함수는 두 데이터프레임을 연결함

```
pandas.concat(objs, axis=0, join='outer', join_axes=None,
    ignore_index=False, keys=None, levels=None, names=None,
    verify_integrity=False, sort=None, copy=True)
```

6절. axis 속성

6절. 병합

```
df1 = pd.DataFrame({'c1': [1, 2, 3, 4],
                    'c2': [5, 6, 7, 8]})
df2 = pd.DataFrame({'c3': ['a', 'b', 'c', 'd'],
                    'c4': [1.2, 3.4, 5.5, 7.6]})
```

```
pd.concat([df1,df2], axis=1)
```

	c1	c2	c3	c4
0	1	5	a	1.2
1	2	6	b	3.4
2	3	7	c	5.5
3	4	8	d	7.6

concat()은 axis 속성에 따라 axis=0 이면 데이터프레임을 위에서 아래로 연결하며, axis=1이면 왼쪽에서 오른쪽으로 연결

6절. axis=0 일 경우 주의사항


```
1  df1 = pd.DataFrame({'c1': [1, 2], 'c2': [3, 4]})
2  df2 = pd.DataFrame({'c1': [5, 6], 'c4': [7, 8]})
```

```
1  pd.concat([df1,df2], axis=0, sort=False)
```

	c1	c2	c4
0	1	3.0	NaN
1	2	4.0	NaN
0	5	NaN	7.0
1	6	NaN	8.0

axis=0일 경우 같은 이름의 열 이름이 있을 경우 위에서 아래로 데이터를 쌓아 연결해 주지만 열 이름이 다를 경우 없는 곳의 데이터가 NaN 값이 됨

6절. concat()과 reset_index()

6절. 병합

연결할 때 내부적으로 인덱스를 사용하므로 두 데이터프레임의 인덱스가 다를 경우에는 reset_index()를 이용해서 인덱스를 초기화 해줘야 함

```
DataFrame.reset_index(self, level=None, drop=False,
                      inplace=False, col_level=0, col_fill='')
```

```
df1 = pd.DataFrame({'c1': [1, 2, 3, 4],
                    'c2': [5, 6, 7, 8]}, index=[0,2,4,6])
df2 = pd.DataFrame({'c3': ['a', 'b', 'c', 'd'],
                    'c4': [1.2, 3.4, 5.5, 7.6]}, index=[0,1,2,3])
```

```
pd.concat([df1,df2], axis=1, sort=False)
```

	c1	c2	c3	c4
0	1.0	5.0	a	1.2
1	NaN	NaN	b	3.4
2	2.0	6.0	c	5.5
3	NaN	NaN	d	7.6
4	3.0	7.0	NaN	NaN
6	4.0	8.0	NaN	NaN

```
df1.reset_index(drop=True, inplace=True)
pd.concat([df1, df2], axis=1)
```

	c1	c2	c3	c4
0	1	5	a	1.2
1	2	6	b	3.4
2	3	7	c	5.5
3	4	8	d	7.6

7절. 정렬

7절. 정렬

행 또는 이름으로 정렬

```
DataFrame.sort_index(axis=0, level=None, ascending=True,
                     inplace=False, kind='quicksort',
                     na_position='last', sort_remaining=True,
                     by=None)
```

값으로 정렬

```
DataFrame.sort_values(by, axis=0, ascending=True, inplace=False,
                      kind='quicksort', na_position='last')
```

```
1  member_df = pd.read_csv("member_data.csv", comment='#')
2  member_df.index = ["동", "서", "남", "북"]
3  member_df
```

	Name	Age	Email	Address
동	홍길동	20	kildong@hong.com	서울시 강동구
서	홍길서	25	kilseo@hong.com	서울시 강서구
남	홍길남	26	south@hong.com	서울시 강남구
북	홍길북	27	book@hong.com	서울시 강북구

예제에 사용할 데이터

7.1. 행 이름으로 정렬

7절. 정렬

- sort_index() 함수는 데이터프레임의 행 이름을 이용해서 정렬

```
1  member_df.sort_index()
```

	Name	Age	Email	Address
남	홍길남	26	south@hong.com	서울시 강남구
동	홍길동	20	kildong@hong.com	서울시 강동구
북	홍길북	27	book@hong.com	서울시 강북구
서	홍길서	25	kilseo@hong.com	서울시 강서구

7.2. 열 이름으로 열 순서 바꾸기

7절. 정렬

- axis=1
- 열의 이름순으로 열의 순서를 바꿈

```
1  member_df.sort_index(axis=1)
```

	Address	Age	Email	Name
동	서울시 강동구	20	kildong@hong.com	홍길동
서	서울시 강서구	25	kilseo@hong.com	홍길서
남	서울시 강남구	26	south@hong.com	홍길남
북	서울시 강북구	27	book@hong.com	홍길북

7.3. 값으로 정렬

7절. 정렬

- 데이터프레임의 값을 기준으로 정렬하려면 sort_values()를 이용

```
1  member_df.sort_values(by=["Email"])
```

	Name	Age	Email	Address
북	홍길북	27	book@hong.com	서울시 강북구
동	홍길동	20	kildong@hong.com	서울시 강동구
서	홍길서	25	kilseo@hong.com	서울시 강서구
남	홍길남	26	south@hong.com	서울시 강남구

7.4. 레벨로 정렬

7절. 정렬

- level 매개변수 이용하면 레벨이 지정되어 있을 경우 레벨로 정렬

```
member_df = pd.read_csv("member_data.csv", comment='#')
```

```
member_df.columns = [["기본정보", "기본정보", "추가정보", "추가정보"],
                     ["이름", "나이", "이메일", "주소"]]
member_df.columns.names = ["정보구분", "상세정보"]
```

```
member_df.index = [["좌우","좌우","상하","상하"],
                   ["동", "서", "남", "북"]]
member_df.index.names = ["위치구분", "상세위치"]
```

```
member_df
```

정렬 전

위치구분	상세위치	기본정보 이름	기본정보 나이	추가정보 이메일	추가정보 주소
좌우	동	홍길동	20	kildong@hong.com	서울시 강동구
	서	홍길서	25	kilseo@hong.com	서울시 강서구
상하	남	홍길남	26	south@hong.com	서울시 강남구
	북	홍길북	27	book@hong.com	서울시 강북구

```
member_df.sort_index(level=["위치구분"])
```

정렬 후

위치구분	상세위치	기본정보 이름	기본정보 나이	추가정보 이메일	추가정보 주소
상하	남	홍길남	26	south@hong.com	서울시 강남구
	북	홍길북	27	book@hong.com	서울시 강북구
좌우	동	홍길동	20	kildong@hong.com	서울시 강동구
	서	홍길서	25	kilseo@hong.com	서울시 강서구

8절. 기초 통계 분석

8절. 기초 통계 분석

- 판다스에서 제공하는 통계분석은 기본적인 기술통계 및 데이터 요약

함수	설명
count	NA를 제외한 개수
min	최소값
max	최대값
sum	합
cumprod	누적합
mean	평균
median	중앙값
quantile	분위수
corr	상관관계
var	표본분산
std	표본 정규분산

예제에 사용할 데이터

```
1  import statsmodels.api as sm
2  iris = sm.datasets.get_rdataset("iris", package="datasets")
3  iris_df = iris.data
4  iris_df.head()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

8.1. 최소값, 최대값, 평균, 중위수

8절. 기초 통계 분석

- min(), max(), mean(), median()

```
1  iris_df.min()
```

```
Sepal.Length       4.3
Sepal.Width          2
Petal.Length         1
Petal.Width        0.1
Species         setosa
dtype: object
```

```
1  iris_df.max()
```

```
Sepal.Length         7.9
Sepal.Width          4.4
Petal.Length         6.9
Petal.Width          2.5
Species        virginica
dtype: object
```

```
1  iris_df.mean()
```

```
Sepal.Length    5.843333
Sepal.Width     3.057333
Petal.Length    3.758000
Petal.Width     1.199333
dtype: float64
```

```
1  iris_df.median()
```

```
Sepal.Length    5.80
Sepal.Width     3.00
Petal.Length    4.35
Petal.Width     1.30
dtype: float64
```

8.2. 요약 통계량

8절. 기초 통계 분석

```
DataFrame.describe(percentiles=None, include=None, exclude=None)
```

- 구문에서...
  - *percentiles* : 출력에 포함될 백분위 수를 0~1사이의 값으로 지정. 기본 값은 [.25, .5, .75]. 25%, 50%, 75% 위치 데이터를 출력
  - *include* : 출력에 포함될 데이터의 유형을 지정합니다. None(기본값) 이면 모든 숫자 타입 열들을 출력에 포함시킵니다. “all”이면 모든 열을 포함합니다. 정수형이면 “int64”, 논리형이면 “bool”, 실수형이면 “float64” 등으로 지정합니다.
  - *exclude* : 출력에서 제외할 데이터의 유형을 지정합니다. None(기본값) 이면 아무것도 제외시키지 않습니다.

8.2. 요약 통계량

- 숫자 데이터
  - 결과의 인덱스에는 count, mean, std, min, max 및 하위 백분위 수, 상위 백분위 수 및 상위 백분율이 포함
  - 기본적으로 하위 백분위 수는 25이고 상위 백분위 수는 75입니다. 50 백분위 수는 중앙값과 같음
- 객체 데이터(예 : 문자열 또는 타임 스탬프)
  - 결과 색인에 count, unique, top 그리고 freq가 포함
  - top가 가장 일반적인 값.
  - 여러 오브젝트 값이 가장 높은 count를 갖는 경우, count와 top 결과는 가장 높은 count를 갖는 오브젝트 값 중에서 임의로 선택.
- DataFrame을 통해 제공되는 혼합 데이터 유형
  - 기본값은 숫자 열의 분석만 반환
  - 데이터프레임이 숫자 열이 없는 개체 및 범주 데이터로만 구성된 경우 기본값은 개체 열과 범주 형 열 모두의 분석을 반환
  - include='all' 매개변수가 제공되면 결과에는 각 유형의 속성이 결합됨

1) 기본 요약 통계량

8절. 기초 통계 분석 > 8.2. 요약 통계량

- iris 데이터의 요약 통계량에는 종(Species) 정보는 출력되지 않음
- 기본적으로 숫자 데이터의 요약 통계량이 출력

```
1  iris_df.describe()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.057333	3.758000	1.199333
std	0.828066	0.435866	1.765298	0.762238
min	4.300000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000

```
1  iris_df.Species.describe()
```

```
count          150
unique           3
top      virginica
freq            50
Name: Species, dtype: object
```

2) include와 exclude

- include 및 exclude 매개 변수를 사용하여 DataFrame에서 출력용으로 분석되는 열을 포함 또는 제한

```
1  import pandas as pd
2  df = pd.DataFrame({'a': [1, 2] * 3,
3                     'b': [True, False] * 3,
4                     'c': [2.0, 4.0] * 3})
```

```
1  df.describe()
```

	a	c
count	6.000000	6.000000
mean	1.500000	3.000000
std	0.547723	1.095445
min	1.000000	2.000000
25%	1.000000	2.000000
50%	1.500000	3.000000
75%	2.000000	4.000000
max	2.000000	4.000000

```
1  df.describe(include=["int64"])
```

	a
count	6.000000
mean	1.500000
std	0.547723
min	1.000000
25%	1.000000
50%	1.500000
75%	2.000000
max	2.000000

```
1  df.describe(include='all')
```

	a	b	c
count	6.000000	6	6.000000
unique	NaN	2	NaN
top	NaN	True	NaN
freq	NaN	3	NaN
mean	1.500000	NaN	3.000000
std	0.547723	NaN	1.095445
min	1.000000	NaN	2.000000
25%	1.000000	NaN	2.000000
50%	1.500000	NaN	3.000000
75%	2.000000	NaN	4.000000
max	2.000000	NaN	4.000000

```
1  df.describe(exclude=["bool", "float64"])
```

8.3. 분산, 표준편차

8절. 기초 통계 분석

```
DataFrame.var(axis=None, skipna=None, level=None, ddof=1,
              numeric_only=None, **kwargs)
```

```
DataFrame.std(axis=None, skipna=None, level=None, ddof=1,
              numeric_only=None, **kwargs)
```

```
1  iris_df.var()
```

```
Sepal.Length    0.685694
Sepal.Width     0.189979
Petal.Length    3.116278
Petal.Width     0.581006
dtype: float64
```

```
1  iris_df.std()
```

```
Sepal.Length    0.828066
Sepal.Width     0.435866
Petal.Length    1.765298
Petal.Width     0.762238
dtype: float64
```

8.4. 공분산, 상관계수

8절. 기초 통계 분석

```
DataFrame.cov(min_periods=None)
```

```
DataFrame.corr(method='pearson', min_periods=1)
```

```
1  iris_df.corr()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	1.000000	-0.117570	0.871754	0.817941
Sepal.Width	-0.117570	1.000000	-0.428440	-0.366126
Petal.Length	0.871754	-0.428440	1.000000	0.962865
Petal.Width	0.817941	-0.366126	0.962865	1.000000

```
1  iris_df.cov()
```

	Sepal.Length	Sepal.Width	Pe	
Sepal.Length	0.685694	-0.042434	1.274315	0.516271
Sepal.Width	-0.042434	0.189979	-0.329656	-0.121639
Petal.Length	1.274315	-0.329656	3.116278	1.295609
Petal.Width	0.516271	-0.121639	1.295609	0.581006

9.1. groupby

9절. 데이터 그룹화 및 집계

- groupby()는 데이터를 구분 할 수 있는 열(column)의 값들을 이용하여 데이터를 여러 기준에 의해 구분하여 그룹화 한 후 기초 통계 함수 등을 적용 할 수 있도록 함

```
DataFrame.groupby(by=None, axis=0, level=None, as_index=True,
                  sort=True, group_keys=True, squeeze=False,
                  observed=False, **kwargs)
```

```
1 import statsmodels.api as sm
2 iris = sm.datasets.get_rdataset("iris", package="datasets")
3 iris_df = iris.data
4 iris_df.head()
```

예제에 사용할 데이터

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

1) 단일 열로 그룹화

https://stackoverflow.com/questions/30490740/move-legend-outside-figure-in-seaborn-tsplot

- groupby 함수의 인수로 그룹화 할 열을 지정

```
1  iris_grouped = iris_df.groupby(iris_df.Species)
2  iris_grouped
```

```
<pandas.core.groupby.groupby.DataFrameGroupBy object at 0x0000014F76F0BEF0>
```

```
1  iris_grouped.mean()
```

Species	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
setosa	5.006	3.428	1.462	0.246
versicolor	5.936	2.770	4.260	1.326
virginica	6.588	2.974	5.552	2.026

2) 다중 열로 그룹화

- groupby 함수의 인수로 그룹화 할 열을 리스트 형식으로 지정

```
1  iris_grouped2 = iris_df.groupby([iris_df.Species, iris_df["Sepal.Length"]])
2  iris_grouped2
```

```
<pandas.core.groupby.groupby.DataFrameGroupBy object at 0x0000014F7712C710>
```

```
1  iris_grouped2.mean().head()
```

		Sepal.Width	Petal.Length	Petal.Width
Species	**Sepal.Length**			
setosa	**4.3**	3.000000	1.100000	0.100
	4.4	3.033333	1.333333	0.200
	4.5	2.300000	1.300000	0.300
	4.6	3.325000	1.325000	0.225
	4.7	3.200000	1.450000	0.200

9.2. 그룹간 반복 처리

9절. 데이터 그룹화 및 집계

- 그룹화 된 데이터에서 그룹의 타입과 그룹 객체를 반복문을 이용해 처리 가능

```
1  for type, group in iris_grouped:
2      print(type, '₩n', group.head())
```

```
setosa
    Sepal.Length  Sepal.Width  Petal.Length  Petal.Width Species
0            5.1          3.5           1.4          0.2  setosa
1            4.9          3.0           1.4          0.2  setosa
2            4.7          3.2           1.3          0.2  setosa
3            4.6          3.1           1.5          0.2  setosa
4            5.0          3.6           1.4          0.2  setosa
versicolor
    Sepal.Length  Sepal.Width  Petal.Length  Petal.Width     Species
50           7.0          3.2           4.7          1.4  versicolor
51           6.4          3.2           4.5          1.5  versicolor
52           6.9          3.1           4.9          1.5  versicolor
53           5.5          2.3           4.0          1.3  versicolor
54           6.5          2.8           4.6          1.5  versicolor
virginica
     Sepal.Length  Sepal.Width  Petal.Length  Petal.Width    Species
100           6.3          3.3           6.0          2.5  virginica
```

10.1. 와이드 포맷과 롱 포맷

10절. 데이터 구조 변경

와이드 포맷(wide format)	롱 포맷(long format)	비고
가로로 긴 형식의 데이터 구조	세로로 긴 형식의 데이터 구조	
열 단위 데이터 구조	행 단위 데이터 구조	
피벗테이블(pivot table)	언피벗테이블(unpivot table)	몰튼(molten) 테이블

와이드 포맷(wide format)

	Ozone	Solar.R	Wind	Temp	Month	Day
1	41	190	7.4	67	5	1
2	36	118	8.0	72	5	2
3	12	149	12.6	74	5	3
4	18	313	11.5	62	5	4
5	NA	NA	14.3	56	5	5
6	28	NA	14.9	66	5	6
7	23	299	8.6	65	5	7
8	19	99	13.8	59	5	8
9	8	19	20.1	61	5	9
10	NA	194	8.6	69	5	10

롱 포맷(long format)

	Month	Day	variable	value
1	5	1	Ozone	41
2	5	2	Ozone	36
3	5	3	Ozone	12
4	5	4	Ozone	18
5	5	6	Ozone	28
6	5	7	Ozone	23
7	5	8	Ozone	19
8	5	9	Ozone	8
9	5	11	Ozone	7
10	5	12	Ozone	16

샘플 데이터

10절. 데이터 구조 변경

```
1  import statsmodels.api as sm
2  airquality_data = sm.datasets.get_rdataset("airquality")
3  airquality = airquality_data.data
4  airquality.head()
```

	Ozone	Solar.R	Wind	Temp	Month	Day
0	41.0	190.0	7.4	67	5	1
1	36.0	118.0	8.0	72	5	2
2	12.0	149.0	12.6	74	5	3
3	18.0	313.0	11.5	62	5	4
4	NaN	NaN	14.3	56	5	5

뉴욕이 대기 질을 측정한 데이터 셋

10.2. melt()를 이용한 언피벗팅

https://pandas.pydata.org/docs/user_guide/reshaping.html#reshaping-by-melt

[Tidy Data 란?](https://vita.had.co.nz/papers/tidy-data.pdf) 7page

```
pandas.melt(frame, id_vars=None, value_vars=None,
        var_name=None, value_name='value', col_level=None)
```

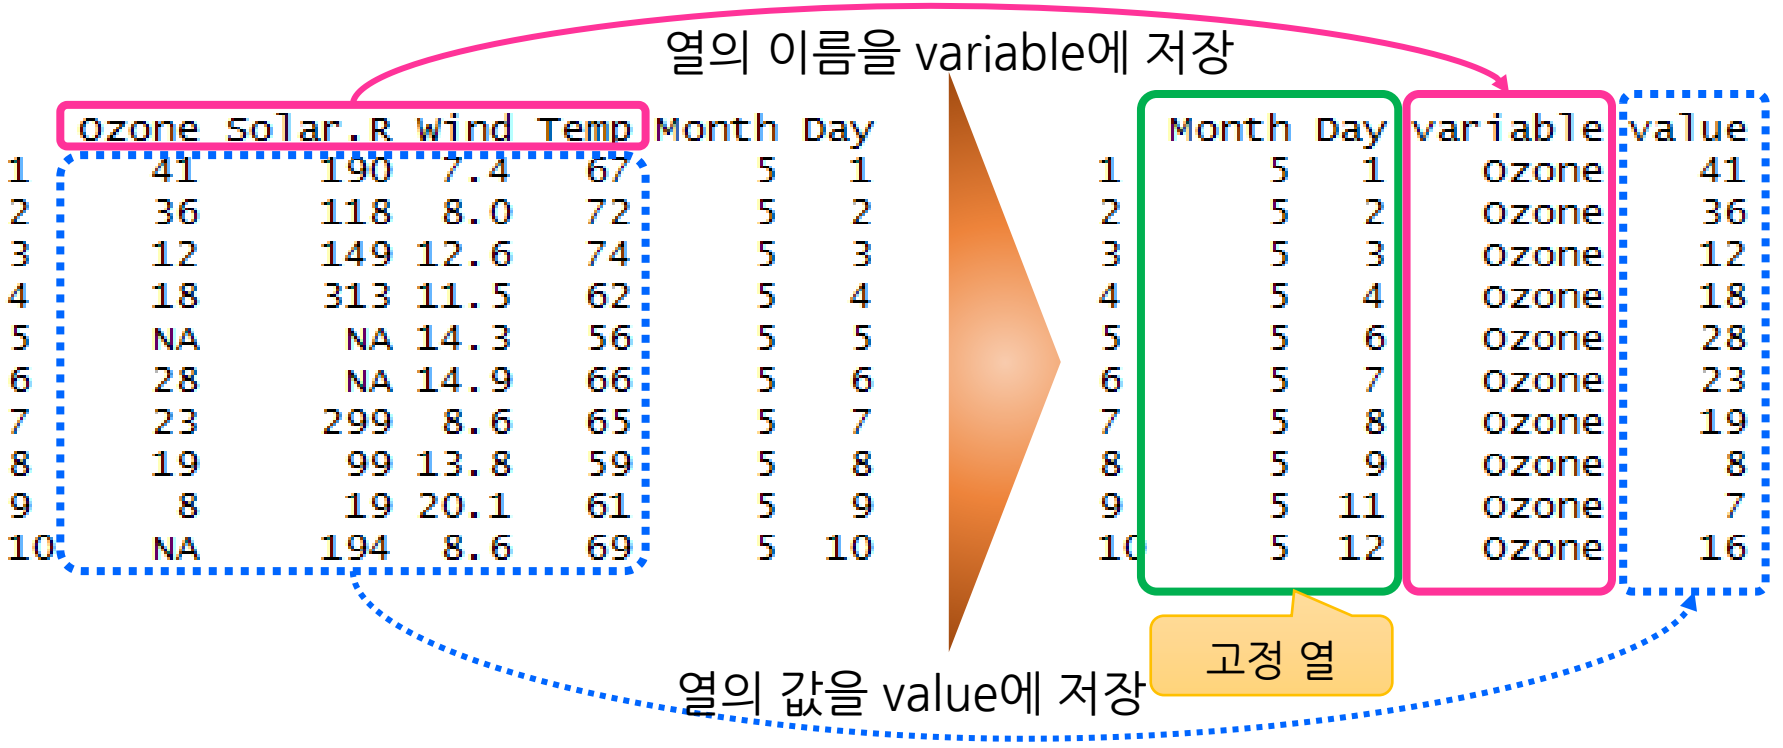

10.2. melt()를 이용한 언피벗팅


```
1  airquality_melted = airquality.melt(id_vars=["Month", "Day"])
```

```
1  airquality_melted.head()
```

	Month	Day	variable	value
0	5	1	Ozone	41.0
1	5	2	Ozone	36.0
2	5	3	Ozone	12.0
3	5	4	Ozone	18.0
4	5	5	Ozone	NaN

10.3. pivot_table()을 이용한 피벗팅


```
DataFrame.pivot_table(values=None, index=None,
        columns=None, aggfunc='mean', fill_value=None,
        margins=False, dropna=True, margins_name='All')
```

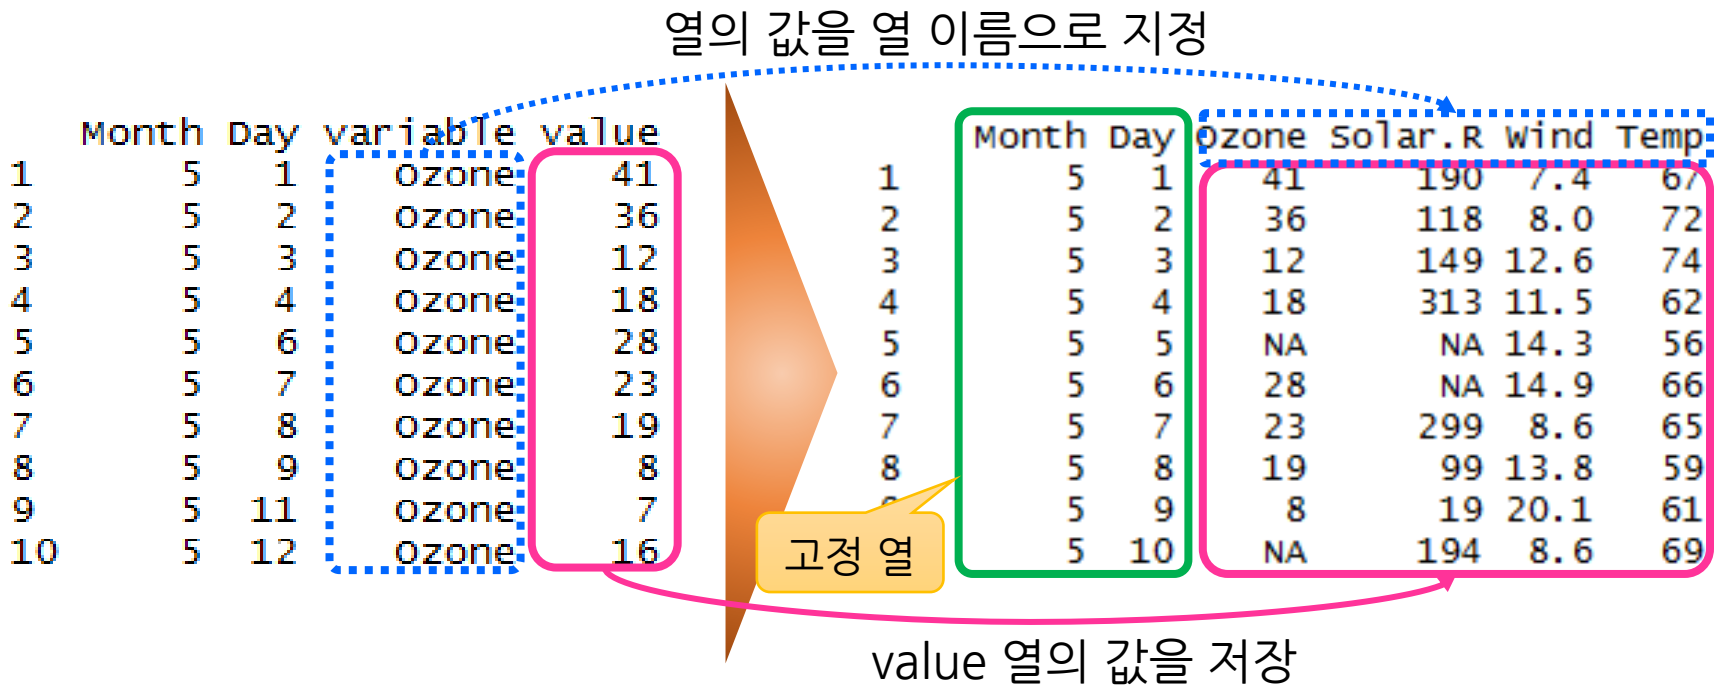

	Month	Day	variable	value
1	5	1	Ozone	41
2	5	2	Ozone	36
3	5	3	Ozone	12
4	5	4	Ozone	18
5	5	6	Ozone	28
6	5	7	Ozone	23
7	5	8	Ozone	19
8	5	9	Ozone	8
9	5	11	Ozone	7
10	5	12	Ozone	16

	Month	Day	Ozone	Solar.R	Wind	Temp
1	5	1	41	190	7.4	67
2	5	2	36	118	8.0	72
3	5	3	12	149	12.6	74
4	5	4	18	313	11.5	62
5	5	5	NA	NA	14.3	56
6	5	6	28	NA	14.9	66
7	5	7	23	299	8.6	65
8	5	8	19	99	13.8	59
9	5	9	8	19	20.1	61
10	5	10	NA	194	8.6	69

10.3. pivot_table()을 이용한 피벗팅

10절. 데이터 구조 변경

```
1 airquality2 = airquality_melted.pivot_table(index=["Month", "Day"],
2                                             columns=["variable"], values=["value"])
```

```
1 airquality2.head()
```

다중 인덱스를 갖는 데이터 프레임

		value			
	variable	Ozone	Solar.R	Temp	Wind
Month	Day				
5	1	41.0	190.0	67.0	7.4
	2	36.0	118.0	72.0	8.0
	3	12.0	149.0	74.0	12.6
	4	18.0	313.0	62.0	11.5
	5	NaN	NaN	56.0	14.3

```
1 airquality2 = airquality2.reset_index(level=["Month", "Day"], col_level=1)
2 airquality2.columns = airquality2.columns.droplevel(level=0)
```

```
1 airquality2.head()
```

결과 데이터프레임에서 인덱스를 제거하고 출력

variable	Month	Day	Ozone	Solar.R	Temp	Wind
0	5	1	41.0	190.0	67.0	7.4
1	5	2	36.0	118.0	72.0	8.0
2	5	3	12.0	149.0	74.0	12.6
3	5	4	18.0	313.0	62.0	11.5
4	5	5	NaN	NaN	56.0	14.3

예제

- 다음과 같은 데이터프레임데이터를 정의하고 melt와 피버팅을 하시오
- pivot_table()과 pivot()함수의 차이

	year	mon	latte	americano	mocha
0	2020	1	410	500	350
1	2020	2	401	483	299
2	2020	3	402	484	300
3	2021	1	400	470	301
4	2021	2	404	486	302
5	2021	3	405	488	300

11.1. apply()

11절. 데이터프레임에 함수 적용하기

```
DataFrame.apply(func, axis=0, raw=False,
                result_type=None, args=(), **kwds)
```

- 구문에서...
  - *func* : 각 열 또는 행에 적용할 함수
  - *axis* : 함수가 적용될 축.
    - 기본값(0 또는 'index')이면 각 열 별로 함수가 적용
    - 1 또는 'columns'이면 각 행 별로 함수가 적용

11.1. apply()

11절. 데이터프레임에 함수 적용하기

- 샘플 데이터

```
1  import statsmodels.api as sm
2  iris = sm.datasets.get_rdataset("iris", package="datasets")
3  iris_df = iris.data
```

```
1  iris_df.head()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

11.1. apply()

11절. 데이터프레임에 함수 적용하기

- 항목 별 동작과 축 별 동작

```
1 import numpy as np
2 iris_df.iloc[:,:-1].apply(np.round).head()
```

넘파이의 round 함수는 항목 별로 동작하는 함수

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
0	5.0	4.0	1.0	0.0
1	5.0	3.0	1.0	0.0
2	5.0	3.0	1.0	0.0
3	5.0	3.0	2.0	0.0
4	5.0	4.0	1.0	0.0

```
1 iris_df.iloc[:,:-1].apply(np.sum)
```

넘파이의 sum 함수는 축 별로 동작하는 함수

```
Sepal.Length    876.5
Sepal.Width     458.6
Petal.Length    563.7
Petal.Width     179.9
dtype: float64
```

11.1. apply()

11절. 데이터프레임에 함수 적용하기

- 시리즈와 람다식의 사용

```
1  iris_avg = iris_df.iloc[:,:-1].apply(np.average)
2  iris_avg
```

```
Sepal.Length    5.843333
Sepal.Width     3.057333
Petal.Length    3.758000
Petal.Width     1.199333
dtype: float64
```

변수 별 평균값을 갖는 시리즈 객체

```
1  iris_df2.apply(lambda x : x-iris_avg, axis=1).head()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
0	-0.743333	0.442667	-2.358	-0.999333
1	-0.943333	-0.057333	-2.358	-0.999333
2	-1.143333	0.142667	-2.458	-0.999333
3	-1.243333	0.042667	-2.258	-0.999333
4	-0.843333	0.542667	-2.358	-0.999333

람다식과 시리즈의 사용 예

11.1. apply()

11절. 데이터프레임에 함수 적용하기

- 함수가 리스트 또는 스칼라를 반환할 경우

```
1  iris_df2.apply(lambda x : list(x-iris_avg), axis=1).head()
```

```
0    [-0.7433333333333341, 0.4426666666666663, -2.3...
1    [-0.9433333333333334, -0.05733333333333368, -2...
2    [-1.1433333333333335, 0.1426666666666665, -2.4...
3    [-1.243333333333334, 0.04266666666666641, -2.2...
4    [-0.8433333333333337, 0.5426666666666664, -2.3...
dtype: object
```

```
1  iris_df2.apply(lambda x : list(x-iris_avg), axis=1,
2                 result_type='broadcast').head()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
0	-0.743333	0.442667	-2.358	-0.999333
1	-0.943333	-0.057333	-2.358	-0.999333
2	-1.143333	0.142667	-2.458	-0.999333
3	-1.243333	0.042667	-2.258	-0.999333
4	-0.843333	0.542667	-2.358	-0.999333

result_type='broadcast' 매개변수를 설정하면 원본 데이터의 열 이름과 구조를 그대로 유지 함

11.2. applymap()

11절. 데이터프레임에 함수 적용하기

- applymap() 함수는 각 요소(element)별로 작동

```
1  iris_df2.applymap(lambda x : x**2).head()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
0	26.01	12.25	1.96	0.04
1	24.01	9.00	1.96	0.04
2	22.09	10.24	1.69	0.04
3	21.16	9.61	2.25	0.04
4	25.00	12.96	1.96	0.04

1) 사용자 정의 함수 사용

- 함수를 적용하면 함수 인자에 시리즈의 항목 하나가 전달

```
1  import pandas as pd
2  x = pd.Series(['Hello', 'Python', 'World'], index=[1,2,3])
3  x
```

```
1    Hello
2    Python
3     World
dtype: object
```

```
1  def my_func(data):
2      return (data, len(str(data)))
```

```
1  x.map(my_func)
```

```
1    (Hello, 5)
2    (Python, 6)
3     (World, 5)
dtype: object
```

map() 함수는 시리즈(Series) 타입에서만 사용할 수 있음

2) 딕셔너리 사용

- 시리즈에 딕셔너리를 적용하면 딕셔너리의 키별로 시리즈의 값에 적용

```
1  z = {"Hello": 'A', "Python": 'B', "World": 'C'}
```

```
1  x.map(z)
```

```
1    A
2    B
3    C
dtype: object
```

3) 시리즈 사용

- 시리즈에 시리즈를 적용하면 원본 시리즈의 값에 적용할 시리즈(arg)의 인덱스 별로 적용

```
1  y = pd.Series(['foo', 'bar', 'baz'],
2                index=['Hello', 'Python', 'World'])
```

```
Hello      foo
Python     bar
World      baz
dtype: object
```

```
1  x.map(y)
```

```
1    foo
2    bar
3    baz
dtype: object
```

4) na_action

- 시리즈가 NaN 값을 포함할 경우 na_action 인자의 값에 따라 결과는 달라짐

```
1  s = pd.Series([1, 2, 3, None])
2  s
```

```
0    1.0
1    2.0
2    3.0
3    NaN
dtype: float64
```

```
1  s.map(lambda x: (x, x**2))
```

```
0    (1.0, 1.0)
1    (2.0, 4.0)
2    (3.0, 9.0)
3    (nan, nan)
dtype: object
```

```
1  s.map(lambda x: (x, x**2), na_action='ignore')
```

```
0    (1.0, 1.0)
1    (2.0, 4.0)
2    (3.0, 9.0)
3           NaN
dtype: object
```

예제

11절

❖1단계 : iris 데이터에서 결측치를 인위적으로 random

하게 열 마다 20씩 결측치를 할당한다

```
import random
random.sample(range(150),20)
```

❖ 2단계 : 결측치가 있는 iris데이터를 출력한다

❖ 3단계 : 결측치를 열평균으로 대체된 iris데이터를 출력

한다.

Pandas가 제공하는 파일 형식

12절

파일 형식	설명	Read	Write
csv	✓ text 형태로 데이터 저장 ✓ 데이터와 데이터 사이에 구분자를 이용해 저장 ✓ 메모장에서도 작성 가능	read_csv	to_csv
excel	✓ 엑셀 프로그램 필요	read_excel	to_excel
Json	✓ Javascript 객체 저장 형식으로 데이터 저장 ✓ 웹 등을 이용해 데이터를 주고받기 위해 사용하는 형식	read_json	to_json
Html	✓ 웹 페이지 파일 형식	read_html	to_html
hd5	✓ 딥러닝에서의 모델 저장 시 사용하는 형식	read_hd5	to_hd5

연습문제 - 실습형

```
import seaborn as sns
iris = sns.load_dataset("iris")
type(iris)
```

```
pandas.core.frame.DataFrame
```

1. iris 데이터에서 처음 다섯개 행만 출력하세요
2. iris 데이터를 데이터프레임 변수인 독립변수 X와 종속변수 y로 나누세요. 종속변수는 species 열입니다.
3. iris 데이터에서 처음 50개행을 빼내서 temp변수에 저장하세요
4. 3번에서 선택한 데이터프레임의 요약정보를 출력하세요. 모든 열에 대해 요약정보가 출력되어야 합니다.
5. versicolor종의 데이터만 iris_versicolor변수에 저장하세요
6. 2번의 X와 y변수를 합해서 iris_df데이터 프레임으로 만드세요

연습문제 - 실습형

7. iris 데이터의 각 열 평균값을 출력하세요.

8. iris 데이터의 각 열들 사이의 상관계수를 출력하세요.

9. iris 데이터에서 각 요소들과 변수별 평균과의 차이를 출력하세요. 다음 그림은 처음 다섯 개 행의 출력 결과입니다.

	sepal_length	sepal_width	petal_length	petal_width
0	-0.743333	0.442667	-2.358	-0.999333
1	-0.943333	-0.057333	-2.358	-0.999333
2	-1.143333	0.142667	-2.458	-0.999333
3	-1.243333	0.042667	-2.258	-0.999333
4	-0.843333	0.542667	-2.358	-0.999333

10. iris 데이터의 종별 평균을 출력하세요.

연습문제 - 실습형

11. iris 데이터에서 각 요소들과 종별 변수의 평균과의 차이를 출력하세요. 각 종별로 3개씩 출력하세요. 다음 그림은 출력 예입니다.

	petal_length	petal_width	sepal_length	sepal_width	species
0	-0.062	-0.046	0.094	0.072	NaN
1	-0.062	-0.046	-0.106	-0.428	NaN
2	-0.162	-0.046	-0.306	-0.228	NaN
50	0.440	0.074	1.064	0.430	NaN
51	0.240	0.174	0.464	0.430	NaN
52	0.640	0.174	0.964	0.330	NaN
100	0.448	0.474	-0.288	0.326	NaN
101	-0.452	-0.126	-0.788	-0.274	NaN
102	0.348	0.074	0.512	0.026	NaN